Pontifícia Universidade Católica de Minas Gerais
Instituto de Ciências Exatas e Informática
Disciplina Aprendizado de Máquina I
Professor Cristiano Rodrigues

Trabalho Prático 1 - Classificação de Exoplanetas

Objetivo

O objetivo do TP 1 é praticar os conceitos aprendidos na disciplina e adquirir experiência no uso de alguns dos principais métodos de classificação, na avaliação de modelos e na interpretação e apresentação de resultados de experimentos.

Para isso, você irá utilizar e comparar métodos de classificação baseados em princípios diferentes em um problema de classificação binária de candidatos a exoplanetas. Além da implementação dos modelos, espera-se que o aluno seja capaz de estruturar um experimento de aprendizado de máquina de forma adequada, justificando as decisões tomadas ao longo do processo.

Tarefas

Neste trabalho você deverá realizar uma comparação entre os seguintes métodos de classificação:

- Naive Bayes
- Decision Tree
- k-Nearest Neighbors (k-NN)
- Support Vector Machines (SVM)
- Random Forest
- Gradient Tree Boosting

Você deverá realizar os experimentos listados abaixo. Pode ser necessário pré-processar os dados (por exemplo, normalização ou padronização) e testar diferentes valores para os hiperparâmetros dos métodos para se obter bons resultados. Caso realize algum tipo de pré-processamento, é necessário justificar sua escolha e explicar seu impacto no desempenho dos modelos.

A avaliação dos métodos deverá ser feita utilizando validação cruzada k-fold com $k = 5$. É importante garantir que o processo de validação seja realizado corretamente, evitando vazamento de dados (*data leakage*), especialmente nos casos em que houver etapas de pré-processamento.

Sempre que houver pré-processamento, este deve ser aplicado dentro do processo de validação (por exemplo, utilizando pipelines), e não antes da divisão dos dados.

A avaliação dos modelos não deve se limitar apenas à acurácia. Sempre que pertinente, utilize outras métricas, como precisão, revocação (recall) e F1-score, justificando a escolha das métricas de acordo com o problema. Discuta também possíveis limitações do uso exclusivo da acurácia. A escolha das métricas deve ser coerente com a distribuição das classes e com o tipo de erro que se deseja evitar.

Os experimentos a serem realizados para cada método são:

- **Naive Bayes**: experimento para servir de baseline
- **Decision Tree**: variar a altura máxima da árvore (incluindo permitir altura ilimitada) e mostrar os resultados graficamente, discutindo o impacto desse hiperparâmetro no modelo
- **SVM**: avaliar os kernels linear, sigmoid, polinomial e RBF, explicando as diferenças entre eles e seus efeitos nos resultados
- **k-NN**: variar o número k de vizinhos e mostrar os resultados graficamente, discutindo o impacto da escolha de k
- **Random Forest**: variar o número de árvores e mostrar os resultados graficamente, analisando o efeito na performance e estabilidade do modelo
- **Gradient Tree Boosting**: variar o número de iterações e mostrar os resultados graficamente, discutindo possíveis efeitos de overfitting

Todos os métodos listados acima estão disponíveis na biblioteca scikit-learn (`https://scikit-learn.org/stable/`) da linguagem Python. Podem ser utilizadas bibliotecas auxiliares, como por exemplo, matplotlib (`https://matplotlib.org`), para geração de gráficos.

Para cada um dos experimentos realizados, explique qual o objetivo do experimento (por exemplo, o significado do hiperparâmetro que está sendo variado) e inclua uma interpretação dos resultados com base nos conceitos teóricos estudados na disciplina. A escolha dos gráficos deve ser adequada ao tipo de análise realizada, e sua interpretação deve ser clara e objetiva, sendo utilizada como base para a tomada de decisão sobre os hiperparâmetros. Sempre que possível, relacione os resultados observados com conceitos como overfitting, underfitting e trade-off bias-variance.

Ao final deverá ser feita uma comparação entre a performance dos métodos, considerando não apenas os valores obtidos, mas também aspectos como estabilidade, sensibilidade a hiperparâmetros e adequação ao problema. Se desejar, você pode incluir a curva ROC e as métricas de precisão e revocação.

Indique qual modelo você escolheria para uso em um cenário prático e justifique sua escolha com base nos resultados obtidos.

Conjunto de Dados

Os métodos serão testados em um problema de classificação binária de candidatos a exoplanetas encontrados pela sonda espacial Kepler da NASA.

Um exoplaneta é um planeta fora do sistema solar (i.e. que não orbita o sol). A sonda primeiro identifica sinais de possíveis exoplanetas, chamados de Kepler Object of Interest (KOI). Porém nem todos os KOIs são de fato exoplanetas, alguns se tratam de falsos positivos de origens diversas. A tarefa é então classificar os KOIs entre exoplanetas confirmados e falsos positivos. Cada observação corresponde a um KOI e as features são características estimadas de cada (possível) exoplaneta (tamanho, temperatura, features da estrela hospedeira, etc).

O conjunto de dados estará pronto para uso e está disponibilizado no arquivo `koi_data.csv`. O arquivo está no formato CSV separado por vírgulas. A primeira coluna identifica o KOI, a segunda traz a sua classificação correta (FALSE POSITIVE ou CONFIRMED) e as demais colunas são features sobre o KOI extraídas de diversas formas. Para este trabalho não será necessário entender o significado das features.

Os dados utilizados neste trabalho foram obtidos a partir do *NASA Exoplanet Archive* (`https://exoplanetarchive.ipac.caltech.edu/`).

Entrega

O trabalho deverá ser entregue no formato de Jupyter (IPython) notebook. O notebook deverá conter todo o código (devidamente comentado) necessário para executar os experimentos, a apresentação dos resultados por meio de texto, gráficos e tabelas, a explicação do que está sendo feito e a interpretação dos resultados.

A organização e a clareza do notebook fazem parte da avaliação do trabalho. O notebook deve ser estruturado de tal forma que seja possível reproduzir os experimentos apenas executando as células em ordem.

Resultados que não puderem ser reproduzidos a partir da execução do notebook poderão ser desconsiderados na avaliação.

O notebook deve apresentar uma sequência lógica clara, incluindo etapas de análise dos dados, pré-processamento, treinamento dos modelos, avaliação e interpretação dos resultados, bem como análise crítica das decisões tomadas.

Critérios de Avaliação

- Implementação correta dos métodos, dos experimentos e da avaliação dos modelos
- Organização das informações apresentadas no notebook
- Apresentação dos experimentos e dos resultados de forma clara, concisa e não ambígua
- Corretude conceitual das explicações e interpretações dos experimentos

A avaliação não será feita pelos valores de acurácia obtidos, mas pelo processo adotado, pela qualidade das decisões metodológicas e pela análise crítica dos resultados.

Trabalhos que apresentarem apenas execução dos modelos, sem análise crítica e justificativas adequadas, não obterão nota máxima.